

Z.AI2API 使用教程

! 社区使用须知与免责声明

铁律要求:

- 严禁商用与社区外传播: 本项目及相关出厂包仅供社区内部交流测试, 禁止转卖、出售或接入任何商业平台。
- 关于源码: 为防止黑产倒卖, 本项目暂不开源, 下载包均为开箱即用的黑盒编译版本。

免责声明: 本项目仅供学习研究、学术探索及接口兼容性测试使用, 按“原样”提供。开发者对任何因使用本项目而产生的风险及损失概不承担任何法律责任。

✨ 核心特性

-  一号一 IP 物理隔离: 基于 Mihomo 代理桥的多端口 SOCKS5 绑定, 每个账号分配专属代理端口与固定出口节点, 根治上游风控“连坐”封号。支持订阅自动导入、节点健康探测与故障 failover。
-  全自动过盾缓冲池: 后台 Worker 自动拉起无头浏览器采集设备令牌与阿里云验证码过盾, 毫秒级响应, 全程零人工干预。
-  无上限账号池预热: 异步预热无限数量账号, 内置自动保活、失败 Cooldown 冷却隔离、每日配额睡眠与风控故障自动摘除恢复。
-  可视化 **Web Dashboard**: 内置管理控制台(默认 <http://127.0.0.1:8088>), 提供账号池管理、订阅绑定、过盾缓冲水位监控及对话测试功能。
-  **OpenAI 标准兼容**: 完全兼容 `/v1/chat/completions`(支持流式 SSE 与非流式)及 `/v1/models`, 支持全系列模型(glm-4.7, GLM-5-Turbo, GLM-5v-Turbo, GLM-5.1, glm-5.2)。

📖 详细部署与配置指南

1. 环境配置说明 (`.env`)

配置文件 `.env` 需与可执行文件置于同一目录下：

变量名	说明
AUTH_TOKEN	管理员密钥 / 客户端 Bearer Token 。所有请求均需携带 Authorization: Bearer <AUTH_TOKEN>。请务必修改为强随机字符串。
PORT / HOST	监听端口与地址，默认 8088 / 0.0.0.0。
ZAI_TOKENS	逗号分隔的多个 Z.AI JWT(可留空，启动后在 Dashboard 粘贴导入)。
MAX_ACCOUNT_INFLIGHT	单账号最大并发(默认 1，防风控)。
ACCOUNT_COOLDOWN_SECONDS	账号故障冷却秒数(默认 120)。
MAX_DAILY_USAGE	单账号每日配额(默认 50, 0=不限)。
FAIL_CLOSED	true = 仅允许代理出口(反封号推荐); false = 允许直连回退。
CAPTCHA_WORKERS / CAPTCHA_BUFFER	过盾 Worker 数 / 缓冲容量。
MIHOMO_SWEEP_INTERVAL	节点健康巡检周期(秒，推荐 15~30)。

代理订阅配置：打开后台 → Mihomo 代理桥 → 添加订阅(粘贴机场订阅 URL)，系统将自动解析节点、测速并分配端口。配置将自动持久化保存于 gateway.json 中。

2. Windows 部署教程

环境要求：Windows 10/11 x64，本机需安装 Chrome 或 Edge。

1. 解压 zai2api_v1.0.0_windows_amd64.zip 到任意目录。

2. 编辑 .env 文件, 修改 AUTH_TOKEN。
3. 双击运行 start.bat 启动网关(停止请运行 stop.bat)。
4. 浏览器访问 <http://127.0.0.1:8088> 进入 Dashboard, 输入 AUTH_TOKEN 登录。
5. 在「账号」页导入 ZAI_TOKEN, 在「Mihomo」页添加订阅。看到账号显示就绪且过盾缓冲 **buffer > 0** 即可使用。

3. Linux 部署教程

环境要求: Linux x64, 需安装 Chromium (apt install chromium)。

1. 解压出厂包

```
tar -xzf zai2api_v1.0.0_linux_amd64.tar.gz
cd zai2api_v1.0.0_linux_amd64
```

2. 编辑配置

```
vim .env
```

3. 启动/停止服务

```
./start.sh # 启动(后台常驻, 日志写入 boot.log)
./stop.sh # 停止
```

Systemd 服务配置 (生产环境推荐):

```
sudo tee /etc/systemd/system/zai2api.service > /dev/null <<'EOF'
```

```
[Unit]
```

```
Description=Z.AI2API Gateway
```

```
After=network-online.target
```

```
[Service]
```

```
Type=simple
```

```
WorkingDirectory=/opt/zai2api
```

```
ExecStart=/opt/zai2api/zai2api
```

```
Restart=always
```

```
RestartSec=5
```

```
[Install]
```

```
WantedBy=multi-user.target
```

```
EOF
```

```
sudo systemctl daemon-reload
```

```
sudo systemctl enable --now zai2api
```

4. Docker / Docker-Compose 部署

解压并启动

```
tar -xzf docker-compose.tar.gz
cd docker-compose

# 修改 .env 中的 AUTH_TOKEN 后启动
docker compose up -d

# 查看日志
docker compose logs -f
```

API 接口与调用说明

接口地址	说明
POST /v1/chat/completions	OpenAI 标准兼容对话接口 (支持流式 / 非流式)
GET /v1/models	获取可用模型列表
GET /	可视化 Dashboard 管理界面
GET /admin/stats	运行统计 (账号池 / 过盾缓冲 / 令牌库)
POST /admin/accounts	账号管理 (导入 / 启用 / 禁用 / 重新预热)

代码调用示例

Python (OpenAI SDK):

```
from openai import OpenAI

client = OpenAI(
    api_key="<YOUR_AUTH_TOKEN>",
    base_url="http://127.0.0.1:8088/v1",
)

# 非流式调用
resp = client.chat.completions.create(
    model="glm-5.2",
    messages=[{"role": "user", "content": "你好"}],
```

```
)
print(resp.choices[0].message.content)

# 流式调用
stream = client.chat.completions.create(
    model="GLM-5.1",
    messages=[{"role": "user", "content": "写一首诗"}],
    stream=True,
)
for chunk in stream:
    if chunk.choices[0].delta.content:
        print(chunk.choices[0].delta.content, end="", flush=True)
```

cURL 请求:

```
curl http://127.0.0.1:8088/v1/chat/completions \
-H "Authorization: Bearer <YOUR_AUTH_TOKEN>" \
-H "Content-Type: application/json" \
-d '{"model": "glm-5.2", "messages": [{"role": "user", "content": "你好"}], "stream": false}'
```

运维注意事项

- 一号一 IP: 保持每个账号分配稳定的专属出口。设置 FAIL_CLOSED=true 可在代理故障时跳过账号而非直连, 有效防连坐封号。
- 数据中心 IP: 上游对机房 IP 过盾频率限制较严, 系统内置自动轮换与故障记忆; 长期高并发使用建议配合住宅 IP 订阅。
- 设备令牌采集: 采集与过盾强制绑定同一出口 IP, 出口切换时系统会自动重新采集, 无需干预。